

AI-сервис техподдержки

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И УСЛОВНЫХ ОБОЗНАЧЕНИЙ

- **ВКР** – выпускная квалификационная работа
- **ИИС** – интеллектуальная информационная система
- **ИИ** – искусственный интеллект
- **НИР** – научно-исследовательская работа
- **ПО** – программное обеспечение
- **ТЗ** – техническое задание
- **API** (Application Programming Interface) – программный интерфейс приложения
- **gRPC** (Google Remote Procedure Call) – система удалённого вызова процедур с открытым исходным кодом
- **LLM** (Large Language Model) – большая языковая модель
- **NLP** (Natural Language Processing) – обработка естественного языка
- **Protobuf** (Protocol Buffers) – протокол сериализации структурированных данных

Реферат

Отчёт по НИР: 50с., 10 рис., 5 табл., 20 источников.

Ключевые слова: ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ, ТЕЛЕГРАМ-БОТ, ЯЗЫК GO, GRPC, QWEN 3.5, МИКРОСЕРВИСЫ, ПРОТОКОЛЫ ПЕРЕДАЧИ ДАННЫХ, ТЕХНИЧЕСКАЯ ПОДДЕРЖКА.

Объектом исследования является процесс автоматизированного взаимодействия с пользователями в системах технической поддержки через современные мессенджеры.

Предмет исследования программная архитектура и методы реализации высокопроизводительного AI-сервиса технической поддержки в мессенджере Telegram на языке Go с использованием протокола gRPC и языковой модели Qwen 3.5.

Цель работы – исследование производительности и эффективности интеграции языковой модели Qwen 3.5 в сервис техподдержки, разработанный на языке программирования Go с использованием высокопроизводительного протокола gRPC.

В ходе работы проводились:

1. Анализ алгоритмов обработки текстовой информации на базе архитектуры Transformer (модель Qwen 3.5).
2. Разработка архитектурного решения для системы обмена данными между интерфейсным модулем (Telegram API) и вычислительным ядром с использованием Protocol Buffers.
3. Оптимизация сетевого взаимодействия и минимизация задержек при генерации ответов нейросетью.

В результате исследования была спроектирована и реализована программная модель AI-сервиса. Использование gRPC позволило обеспечить строгую типизацию данных и высокую скорость обмена сообщениями, что критично для работы LLM в реальном времени. Применение модели Qwen 3.5 показало высокую релевантность ответов на технические запросы пользователей.

Степень внедрения: разработанный прототип сервиса готов к интеграции в системы клиентской поддержки малых и средних ИТ-предприятий.

Эффективность: использование разработанного решения позволяет автоматизировать до 70% типовых запросов первой линии поддержки, снижая нагрузку на персонал и сокращая время ожидания ответа до минимальных значений.