

Разработка AI-сервиса технической поддержки

Микросервис helperbot-ai на локальной языковой модели: gRPC-контракт, полный контекст диалога, ограничение нагрузки средствами СУБД

Автор: Гневнов Артём Евгеньевич, 4 курс, очная форма обучения · Руководитель: Жуков Николай Николаевич, канд. физ.-мат. наук, доцент

1 ВВЕДЕНИЕ

Объём обращений в техподдержку растёт, ручная обработка первой линии не справляется с пиковой нагрузкой.

Облачные сервисы (OpenAI, Yandex GPT) требуют передачи данных внешнему провайдеру, Rasa — разметки корпуса намерений, Botpress — платной лицензии: готового локального решения нет.

2 ЦЕЛЬ И ЗАДАЧИ

Разработать микросервис AI-техподдержки: обработка обращений локальной языковой моделью с историей диалога, ограничением нагрузки и интеграцией в систему заявок.

- 1 Анализ AI-решений


2 Требования к сервису

3 Архитектура, протокол
- 4 Реализация на Go

5 Интеграция с Helperbot

6 Тесты и развёртывание

3 МАТЕРИАЛЫ И МЕТОДЫ: АРХИТЕКТУРА И ПОТОК ОБРАБОТКИ



4 ПРИНЯТЫЕ РЕШЕНИЯ

- Многослойная архитектура api → service → repository с инверсией зависимостей

– Rate limit скользящим окном (10 сообщений / 300 с) — SQL-фильтрацией, без Redis
- Типизированная ошибка ErrTooManyRequests распознаётся клиентом через errors.Is

– Кастомная модель support-bot: temperature 0.2, num_ctx 4096, русскоязычный промпт

5 РЕЗУЛЬТАТЫ

5	6+8	2	2	10	1
решений сравнено	требований	gRPC-метода	таблицы БД	юнит-тестов	команда запуска

6 ВЫВОДЫ

Цель достигнута: обращения обрабатывает локальная модель Qwen2.5, данные не покидают организацию. Апробация — ЦБС Петроградского района.

7 РАЗВИТИЕ

- Векторный поиск по базе знаний (RAG)

– Few-shot примеры в системном промпте

– Переход на qwen2.5:7b, чтение с реплики