

Как ИИ-ассистент отвечает без единого облака


Разбираем на примере helperbot-ai — микросервиса, который обрабатывает диалоги локальной языковой моделью прямо на инфраструктуре организации.

АГ

Гневнов Артём Евгеньевич
Автор · ВКР, 09.03.01, РГПУ им. А. И. Герцена, 2026

01 Путь одного сообщения

От вопроса пользователя в Telegram до ответа языковой модели — шесть шагов меньше чем за пару секунд.



02 Ограничение нагрузки без лишней инфраструктуры

Лимит запросов к модели реализован обычным SQL-запросом — отдельный сервис вроде Redis не понадобился.

10 / 5 мин

запросов на пользователя за скользящее окно — значения по умолчанию, задаются переменными окружения

REQUESTS_COUNT · REQUESTS_REFRESH_INTERVAL

4096

токенов — размер контекстного окна модели: столько истории диалога учитывается при ответе

num_ctx в Support.Modelfile

03 Локальная модель вместо облачного API

Ключевое архитектурное решение работы — и его последствия.

выбрано: локально (Ollama)

Данные диалогов не покидают инфраструктуру организации

Нет платы за токены и зависимости от тарифов провайдера

Работает без интернета к внешнему AI-сервису

альтернатива: облачный API

Выше качество ответов на сложных вопросах

Не требует ресурсов сервера под инференс

Данные уходят внешнему провайдеру, оплата по вызовам

04 Хранение диалога — всего 2 таблицы

Схема сознательно минимальна: пользователи и заявки живут в другой базе, здесь — только сам диалог.

chats		messages
id : UUID «PK»	chat_id → chats.id (логическая связь, без FK)	chat_id : UUID
user_id : UUID		role : "user" / "assistant"
created_at : TIMESTAMPTZ		content : TEXT

05 Из чего это сделано

- Go + Uber FX
- gRPC + Protobuf
- PostgreSQL + pgx
- Ollama · qwen2.5:1.5b
- Docker Compose

// об авторе	// источник материала	// репозиторий
Гневнов Артём Евгеньевич обучающийся 4 курса, направление 09.03.01 «Информатика и вычислительная техника» РГПУ им. А. И. Герцена, Санкт-Петербург, 2026	ВКР «Разработка AI-сервиса техподдержки» Руководитель — Жуков Н. Н., доцент каф. ИТиЭО	helperbot-ai (в составе комплекса Helperbot)