

1. Сценарий демонстрации

Демонстрация построена по принципу «снизу вверх»: сначала показывается развёртывание инфраструктуры, затем — пользовательский сценарий взаимодействия, и в финале — внутренние артефакты (логи, БД, gRPC-вызовы) для подтверждения корректности работы сервиса.

Шаг 1. Развёртывание комплекса (1 минута)

Действие. В терминале выполняется команда:

```
make compose-up
```

Что комментировать. Команда автоматически клонирует или обновляет репозитории, собирает Docker-образы, запускает контейнеры в правильном порядке (сначала PostgreSQL-мастера, затем миграции, затем прикладные сервисы) и создаёт кастомную модель `support-bot` в Ollama.

Если уже запущено заранее. Пропустить шаг, выполнить `docker ps` и прокомментировать состав комплекса по выводу.

Шаг 2. Авторизация в Telegram-боте (30 секунд)

Действие. Открыть диалог с ботом в Telegram, отправить команду `/start`.

Что комментировать. Бот распознаёт пользователя по Telegram ID, обращается к `helperbot-core` через gRPC, и в зависимости от роли формирует динамическое меню. Для пользователя с ролью администратора в меню присутствует кнопка «Чат с ИИ» — именно она открывает доступ к AI-сервису.

Шаг 3. Создание нового диалога с AI (30 секунд)

Действие. Нажать кнопку «Чат с ИИ».

Что комментировать. При первом обращении пользователя `helperbot-tg` обнаруживает отсутствие `ChatID` в кэше и вызывает `ChatService.NewChat`, который проксируется через `helperbot-core` в `helperbot-ai`. AI-сервис генерирует новый UUID, сохраняет запись в таблице `chats` и возвращает идентификатор. Пользователю отправляется приветственное сообщение.

Контрольный вывод в логах (второй терминал):

```
helperbot-ai /chat.ChatService/NewChat OK ~5 ms
```

Шаг 4. Базовый сценарий: вопрос — ответ (1 минута)

Действие. Отправить боту первый демонстрационный вопрос (см. список в разделе 2, вопрос 1).

Что комментировать. `helperbot-tg` переводит пользователя в состояние `PendingActionWaitAiAnswer`, вызывает `ChatService.SendMessage`. AI-сервис проверяет лимит запросов SQL-фильтрацией по временной метке, загружает историю диалога из PostgreSQL (на первом сообщении она пуста), формирует контекстный запрос к Ollama, получает ответ, сохраняет в БД пару «вопрос — ответ» и возвращает результат по цепочке.

Ожидаемое время инференса: 3–15 секунд в зависимости от ресурсов хоста.

Шаг 5. Демонстрация контекстной осведомлённости (1 минута)

Действие. Отправить уточняющий вопрос (раздел 2, вопрос 2), не повторяя контекст из первого.

Что комментировать. При формировании запроса к Ollama AI-сервис загружает **всю** историю диалога из таблицы `messages` в хронологическом порядке и передаёт её модели. Поэтому ответ учитывает предыдущий обмен, а не отвечает «как с нуля». Это ключевое отличие от stateless-чатботов.

Шаг 6. Демонстрация контекстной осведомлённости (1 минута)

Действие. Отправить уточняющий вопрос (раздел 6, вопрос 2), не повторяя контекст из первого.

Что комментировать. При формировании запроса к Ollama AI-сервис загружает **всю** историю диалога из таблицы `messages` в хронологическом порядке и передаёт её модели. Поэтому ответ учитывает предыдущий обмен, а не отвечает «как с нуля». Это ключевое отличие от stateless-чатботов.

Если демонстрация устная — попросить присутствующих оценить, насколько ответ согласуется с предыдущим контекстом.

Шаг 7. Демонстрация эскалации к оператору (1 минута)

Действие. Отправить заведомо узкоспециализированный вопрос (раздел 6, вопрос 3).

Что комментировать. Системный промпт модели `support-bot` содержит инструкцию: при незнании ответа предлагать обратиться к живому оператору. Модель должна сформировать вежливый отказ с рекомендацией эскалации. Это реализация одного из функциональных требований без дополнительного программного кода — исключительно через конфигурацию языковой модели.

2. Перечень демонстрационных материалов

Вопросы для базового сценария (шаги 5–6)

1. **Первое сообщение:** «Здравствуйте! Подскажите, как зарегистрировать нового читателя в системе?»
2. **Уточняющее сообщение (с опорой на контекст):** «А какие документы для этого нужны?»

Вопрос для демонстрации эскалации (шаг 7)

1. «Какой инвентарный номер у сервера, на котором развёрнута АБИС нашего филиала?» — модель не располагает специфической информацией и должна предложить обратиться к оператору.

3. Завершение демонстрации

После прохождения сценария проговариваются итоги:

«Таким образом, продемонстрирована работа AI-сервиса `helperbot-ai` в составе программного комплекса `Helperbot`. Подтверждены: автоматическая обработка обращений локальной языковой моделью без передачи данных вовне, сохранение контекста диалога между сообщениями, корректное срабатывание ограничения частоты запросов и эскалация к живому оператору при невозможности ответа. Развёртывание всего комплекса автоматизировано и выполняется единственной командой».